

対話型トイドローン開発に向けた AI による左右方向の音源判別

大和大学 ○佐藤 敦, 前田 陽一郎

1. 緒論

現在、ドローン技術は災害救助や物流など幅広い分野で普及している。また、ChatGPT 等に代表される大規模言語モデルの進展により、ドローンを人と対話可能なエージェントとする可能性が広がっている。特に、重量 100 g 以下のトイドローンは航空法の規制外であり、安全かつ小規模空間でも柔軟な運用が可能である。しかし、飛行中に発生するプロペラ騒音は音声認識の大きな妨げとなる。そこで本稿では、対話機能の基礎技術として、発話者の方向を把握するための音源方向判別に着目する。

本研究では、人と会話できる対話型トイドローンの開発に向け、機械学習の 2 クラス分類を用いた左右方向の音源判別を試みた。

2. 研究方法

図 1 に実験装置の概要図を示す。図 1 の実験装置では、簡易無響ボックス（静科社製、中高周波用大型）内において、トイドローン（Ryze Tech 社製、Tello）が釣り糸によって吊り下げられている。トイドローンは、図 1 の紙面手前方向を機首方向とした。




Fig. 1 Overview of experimental setup

実験では、トイドローン左右の MEMS マイク（Hailege 社製、SPH0645LM4H）により、両側の各 Bluetooth スピーカー（Boompods 社製、zero speaker）からの音を録音する。Bluetooth スピーカーは、MEMS マイクから 15 cm 離れた箇所に固定している。Bluetooth スピーカーから流す音声には、LibriSpeech ASR Corpus の train-clean-100 に含まれる話者 ID19、章 ID198 の音声データを用いた。LibriSpeech ASR Corpus は、世界中の音声認識（ASR：Automatic Speech Recognition）研究で広く使用されている英語音声データセットである。ほとんどの環境において、会話距離での発話レベルは 55~66 dBA と報告されている¹⁾。よって、Bluetooth スピーカーからの音の大きさは、MEMS マイク付近で最大 66 dBA 程度とした。本研究での音の大きさは、データロガー騒音計（サトテック社製、SL-4023SD）により測定した。トイドローンのプロペラは、4 個のモータそれぞれに直流安定化電源（松定プレシジョン社製、TB80V14A360W）から定電圧を印加して回転させた。なお、トイドローンの重量は、バッテリーを搭載した市販状態で 84.3 g であり、離陸し始める電圧は 1.8 V である。

本研究では、MEMS マイクによる録音データの特徴量が MFCC（メル周波数ケプストラム係数）による処理に基づき抽出される。MFCC は、人間の聴覚が周波数を線形ではなく非線形に知覚する性質を反映した音響特徴量である。MFCC は、標準的な 13 個の特徴量とする。MFCC の差を使えば、左右方向の音源判別において環境音と人の声のある程度区別できる可能性がある。機械学習（教師あり学習）では、MEMS マイクによる録音データより抽出した

左右 MFCC 差（左チャンネルの MFCC-右チャンネルの MFCC）に基づいて 2 クラス分類する。2 クラス分類では、トイドローンの機首方向から見て左側の Bluetooth スピーカーから音声が行き流される場合（左側音声再生）を 0、右側の Bluetooth スピーカーから音声が行き流される場合（右側音声再生）を 1 とする。以後、右側音声再生の確率（1 と判断される確率）を右側音源確率と呼称する。この確率以上なら〇〇とする確率しきい値は、50 %とした。

機械学習には、クラウド型機械学習プラットフォームの Azure Machine Learning を用いた。学習モジュールには、SVM（Support Vector Machine）に基づく 2 クラス分類器である Two-Class Support Vector Machine を用いた。SVM は、クラス間のマージンを最大化する決定境界を求める教師あり学習手法である。左右方向の音源判別を行う Azure Machine Learning パイプラインを図 2 に示す。このパイプラインは、train（学習用データ）に基づいて 2 クラス分類モデルを構築し、test（評価用データ）を分類する。

機械学習の対象は、MEMS マイクにより録音した全 504 秒の音声の中央部 500 秒間とした。図 2 のパイプラインでは、前半 250 秒を学習用データ、後半 250 秒を評価用データとした。音声データは 5 秒ごとに分割し、各区間で左チャンネルおよび右チャンネルの MFCC を算出した。さらに、各 MFCC の特徴量の平均値を求め、左チャンネルの MFCC から右チャンネルの MFCC を差し引くことで、左右 MFCC 差を算出した。なお、算出には Python ライブラリ librosa を用いて作成した自作プログラムを使用した。プロペラ音は、左右方向の音源判別に影響を与える。次章では、トイドローンの各モータに印加する電圧（以後、モータ駆動電圧と呼称）を変化させ、右側音源確率に及ぼす影響を調査した。




Fig. 2 Pipeline for two-class classification

3. モータ駆動電圧が右側音源確率に及ぼす影響

表 1 に実験時の音の大きさ、図 3 にモータ駆動電圧と右側音源確率の関係を示す。図中のエラーバーは、最大値と最小値である。

Table 1 Sound levels during experiment

Background noise (Box closed)	Approximately 32 dBA	
Background noise near MEMS microphone (Box open)	0 V	Approximately 37 dBA
	0.6 V	Approximately 70 dBA
	1.2 V	Approximately 92 dBA
	1.8 V	Approximately 97 dBA




Fig. 3 Effect of voltage on probability without band-pass filtering

図3を見ると、モータ駆動電圧の増加に伴い、右側音声再生時の右側音源確率が減少している。原因として、人の声とプロペラ音の周波数帯が被っており、モータ駆動電圧の上昇によりプロペラ騒音が支配的となったことが挙げられる。研究では、目視検査の精度は一般的に70～80%程度であることが報告されている²⁾。モータ駆動電圧0.6V以上では、右側音声再生での右側音源確率の最小値が70%を下回っており実用性に課題が残る。そのため、機体停止時にのみ左右方向の音源判別が可能であると考えられる。

公衆電話網では、300 Hz～3400 Hzの周波数成分のみ伝送される³⁾。さらに、低周波騒音は一般に10～250 Hzの周波数帯域に音響エネルギーが卓越する広帯域騒音を指す⁴⁾。低周波騒音の発生源には、換気システムや輸送車両が挙げられる。よって、300～3400 Hzの音声帯域にバンドパスフィルタを適用して左右MFCC差を算出すれば、低周波騒音の影響を低減できる可能性がある。録音データに300～3400 Hzのバンドパスフィルタを適用し、モータ駆動電圧と右側音源確率の関係を調査した結果を図4に示す。




Fig. 4 Effect of voltage on probability with band-pass filtering

図4より、0.6Vにおける右側音声再生での右側音源確率の最小値が70%を超えており、多少の改善が見られる。しかし、1.8Vでは右側音源確率の最小値が50%を下回り、判別困難である。

以上より、対話型トイドローンの実現に向けては、PCを介して必要最小限の制御指令をFSK音響信号として送信する方式を検討したい。FSK音響信号は、周波数を切り替えて情報を表す音の信号である。例えば、低い周波数の音:0、高い周波数の音:1のように音の高さを切り替えて信号を送る。本研究では、音声文字起こしたテキストをUTF-8形式のビット列に変換し、各ビットに対し異なる周波数の正弦波を割り当てて2値FSK音響信号を生成した。ビット0には6000 Hz、ビット1には9000 Hzを対応させ、1ビットの継続時間は0.05 sとした。次章では、この周波数偏移変調(FSK)を用いて音響信号とした音声を使用した。なお、2729秒の音声データのうち、冒頭の500秒間を機械学習の対象とした。音声除去されるため、バンドパスフィルタは適用していない。

4. FSK音響信号が右側音源確率に及ぼす影響

表2に実験時の音の大きさ、図5にモータ駆動電圧と右側音源確率の関係を示す。図中のエラーバーは、最大値と最小値である。

Table 2 Sound levels during experiments with FSK acoustic signals

Background noise (Box closed)	Approximately 32 dBA	
Background noise near MEMS microphone (Box open)	0 V	Approximately 38 dBA
	0.6 V	Approximately 68 dBA
	1.2 V	Approximately 82 dBA
	1.8 V	Approximately 89 dBA




Fig. 5 Effect of voltage on probability using FSK acoustic signals

図5を見ると、1.2Vにおける右側音声再生時の右側音源確率の平均値が20%程度向上したように見える。しかし、表2より実験時のプロペラ音が比較的小さかった可能性もあり、FSK音響信号の効果のみに起因するとは断定できない。結論として、FSK音響信号の導入により改善する可能性はあるが、機体が離陸するようなプロペラ音が支配的な状況では、劇的な改善は見込みにくい。

モータ駆動電圧1.8Vは、地面効果を受けた状態で機体がホバリングし始める値であり、実際の飛行中のプロペラ音はより大きい可能性がある。音響ビームフォーミングは、複数のマイクロホンを用いて特定方向から到来する音を強調し、それ以外の方向からの音を抑制する技術である。今後は、音響ビームフォーミングを取り入れ、飛行中でも会話可能なトイドローンの開発を目指す。

5. 結論

本研究の実験条件において、以下のことが明らかとなった。

- (1) プロペラ音の増大は、音源の左右判別精度を低下させる。
- (2) ホバリング開始相当のモータ駆動条件では、プロペラ音の影響で音源の左右判別は困難であり、FSK音響信号を導入しても劇的な改善が期待できない。
- (3) トイドローンの停止状態では、音源の左右判別が可能である。

参考文献

- 1) Pearsons et al.: Speech levels in various noise environments, Report No. EPA-600/1-77-025, U.S. Environmental Protection Agency, Washington, DC, 1977.
- 2) J. E. See: Visual inspection: A review of the literature, Sandia National Laboratories, Report No. SAND2012-8590, 2012.
- 3) Y. Hu et al.: Effects of introducing low-frequency harmonics in the perception of telephone speech, Journal of the Acoustical Society of America, Vol. 128, pp. 1280–1289, 2010.
- 4) M. Pawlaczyk-Luszczynska et al.: Assessment of annoyance from low frequency and broadband noises, International Journal of Occupational Medicine and Environmental Health, Vol. 16, No. 4, pp. 337–343, 2003.